面向语音模型的 FPGA 矩阵计算架构与可观测优化设计报告

本项目固定电脑端输入准备、FPGA 执行计算与搬运的整体框架，采用 W7p8 权重、A16 激活和 C48 累加。当前交付包含可执行的统一小图 RTL 候选、局部矩阵测量、权重量化历史实验、修复后的技能包，以及标准形式的 Roofline 定位。以下按照选题指南 3.3.5.3 组织。目录对照 3.3.5.4；短视频 PPT 不设封面，讲稿另存为 Markdown。

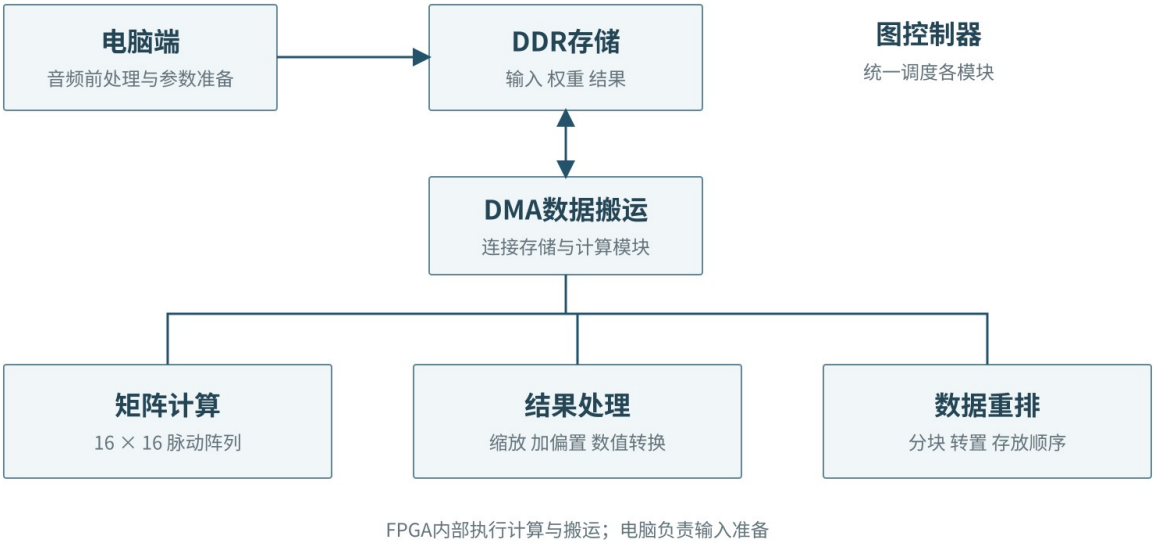
1 选题背景与创新点

语音模型包含密集矩阵乘加，也需要缩放、加偏置、数值转换和数据重排。仅增加计算单元不能保证整条链路更快：输入准备、重复读取、部分和收集与输出排空都可能限制吞吐。本项目围绕固定数值合同设计矩阵核心，再用真实搬运记录和模块状态分析执行过程。

已有工作中，Eyeriss 强调数据流与片上复用，Gemmini 展示矩阵阵列、缓存与软件接口的分层组织；本项目借鉴其表达和分析方法，实际实现与测量以本工程源码、日志为准，不将文献性能当成本项目结果。

项目设计特点为：特殊权重编码对应的 16×4 位幅值乘法及移位恢复；16×16 阵列映射 32×32 逻辑块；C48 到 A16 的融合后处理；搬运账本与活动波形协同定位 Roofline。它们是本项目的实现特点，不宣称首次提出相关算法。

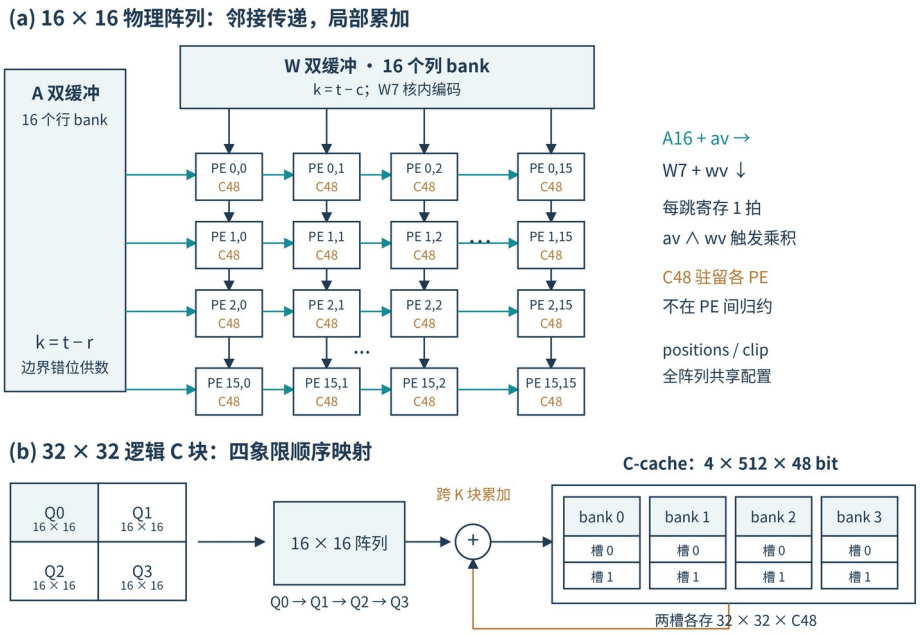
2 设计原理与功能框图



整体框图

电脑负责音频前处理、参数检查与输入打包。图控制器调度矩阵、结果处理、数据重排及其 DMA 通路。展示名称“结果处理”表示本图中的缩放、加偏置和数值转换等工作；源代码中的 vector 模块名称保持不变。数据重排表示分块、转置与存放顺序调整，DMA 表示实际搬运，二者分别保留。

2.1 阵列组织



阵列与分块

物理阵列为 16×16，A 沿行向右、W 沿列向下传递，valid 跟随操作数。每个 PE 持有局部 C48 累加，C 不在相邻 PE 间做归约。32×32 逻辑输出块分四象限执行，跨 K 块部分和由 C 缓存保存。A 缓存 4096 B、W 缓存 2048 B、C 缓存 12288 B；这些是源级数组容量，不是综合后的 BRAM 占用。

2.2 固定量化合同

W7p8 每个权重占 1 B：bit7 为偶校验，bit6 为符号 S，bit5:4 为索引 J，bit3:0 为幅值 M。p=positions[J]，普通值为 w=(−1)^S×M×2^p；启用 clip 且 p=12、M≥8 时幅值为 32767。它与普通二补码 INT7 不同。

A16 包括−32768。PE 以无符号 16 位保存绝对值，计算幅值乘法、移位与 clip 修正，恢复符号后形成 32 位乘积，符号扩展到 C48。累加按 2^48 回绕。输出链为 C48 转 FP32 最近偶数舍入、单次舍入 FP32 FMA 执行 scale/bias、可选 ReLU、最近偶数舍入与饱和到 A16。

融合只在显式允许且消费者兼容时启用；其他情况保留 C48 输出。一个 32×32 块若避免一次 C48 写回与一次重读，可少搬 12288 B 中间结果。这是满足融合条件的格式推导，不是整机流量下降比例。

同元素数下，FP32 权重 4 B 变为 W7p8 的 1 B，激活 4 B 变为 A16 的 2 B，累加结果使用 C48 的 6 B。矩阵有用乘加次数不因位宽下降而改变。

3 软硬件划分依据与接口设计

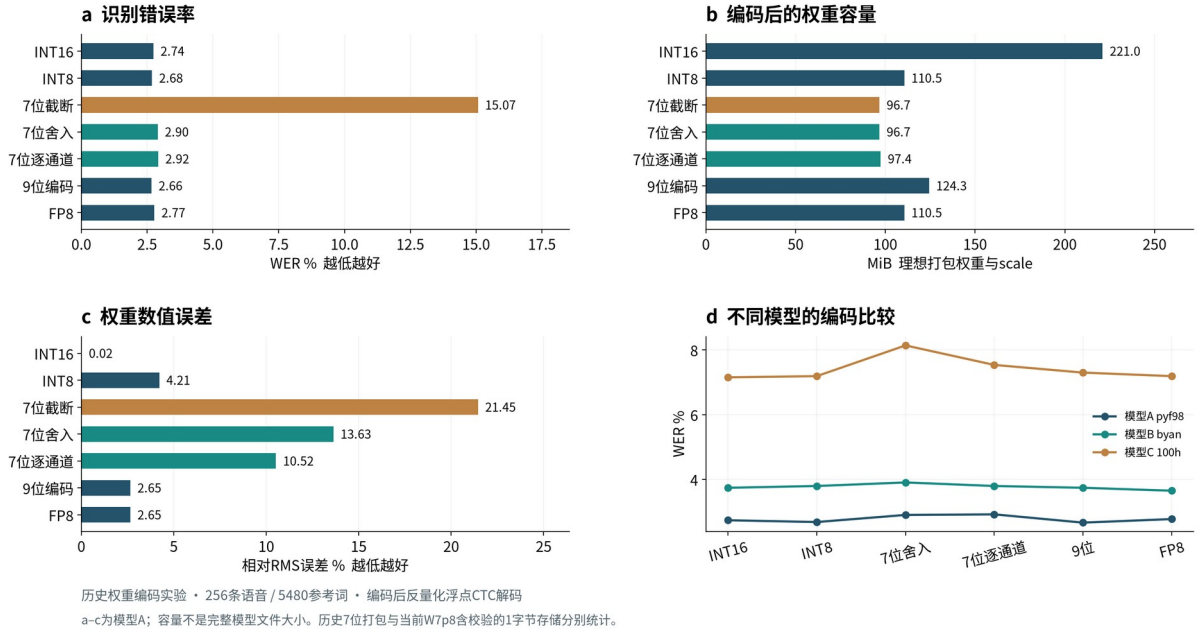
电脑适合完成音频准备、文件与模型参数解析、校验和任务组织；FPGA 适合重复矩阵乘加与约定数值处理。旧版 base_v021.py 存在电脑逐算子调度，新版统一顶层引入 PL 图控制器；本报告分别保留来源，不把两者描述成同一次执行。

接口或数据	合同	依据
控制口	AXI4-Lite，24 位地址、32 位数据	统一顶层端口
数据口	AXI，40 位地址、128 位数据	统一顶层与 DMA
时钟	当前为单时钟逻辑候选	RTL 顶层

接口或数据	合同	依据
权重	1 B 存储，7 位数值加偶校验，位置表与 clip 随配置保留	主机与 PE 解释一致
输入及输出	A16；支持 C48 回退或兼容条件下融合 A16 输出	统一图与融合合同
正常完成	b_pending=0 且 quiesced=1	测试检查
写响应故障	错误隔离并要求复位，不能将超时作为成功	hold-B 负向测试

4 优化过程与性能资源对比

4.1 权重量化比较



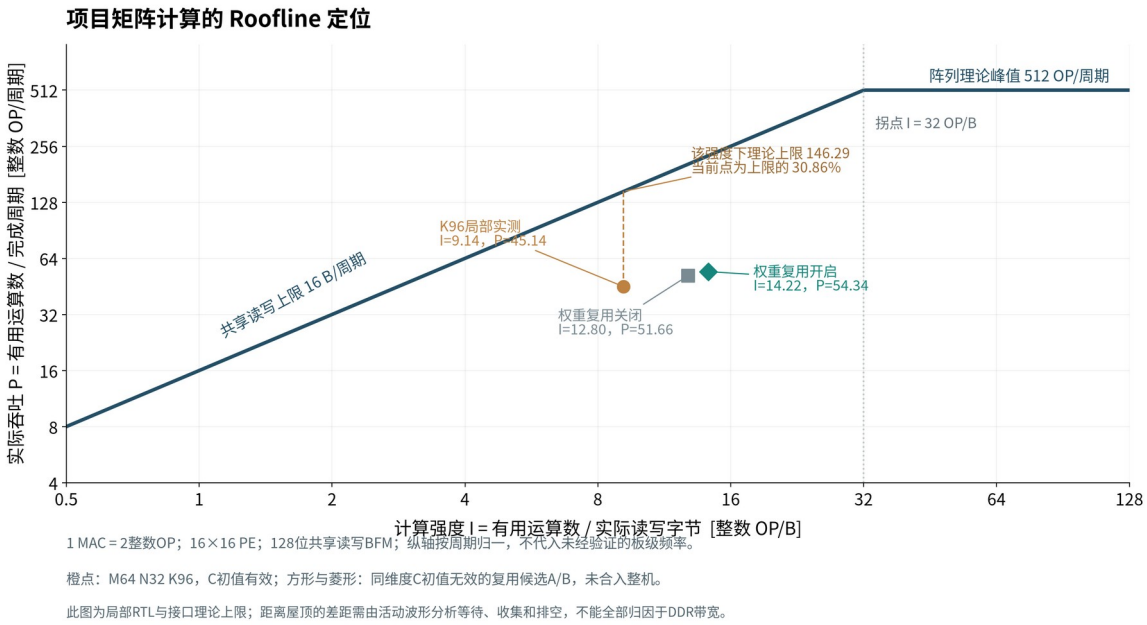
量化四宫格

四宫格只采用 2026-10-05 同批权重编码实验，不含 LoRA。256 条 LibriSpeech test-clean 语音、5480 参考词；rank≥2 权重编码后反量化，激活等保持 FP32，ESPnet CTC greedy 解码。a 至 c 为 pyf98 模型，d 为三模型结果。容量是理想编码权重载荷加 scale，不是完整 ONNX 文件或当前含校验 W7p8 的容量。

模式	pyf98 WER	权重与 scale 容量 MiB
INT16	2.7372%	221.045
INT8	2.6825%	110.523
7 位截断	15.0730%	96.708
7 位舍入	2.9015%	96.708
7 位逐通道	2.9197%	97.368
9 位编码	2.6642%	124.338
FP8 E4M3	2.7737%	110.523

表中容量的精确重算值以 data/encoding_results.json 为准；图中按一位小数显示。此处 WER 用于编码比较，不是 A16/C48 硬件全图精度结果。

4.2 Roofline 标准形式与测量位置



Roofline 定位

定义 N=2MKN，1 MAC 按 2 个整数 OP 计；Q 为指定存储边界实际读加写字节；T 为完整完成窗口。本例输入与输出均为完整有效拍，valid 字节与 bus 字节一致；一般情况下应计入接口补齐与无效拍占用。计算强度 I=N/Q，吞吐 P=N/T，理论屋顶 P_roof=min(P_peak,B_peak×I)。使用整数 OP/周期与 B/周期，避免把未经验证的频率换算为板级 GOPS。

16×16 阵列按每 PE 每周期至多 1 MAC，理论峰值为 512 OP/周期。该组 BFM 的 DUPLEX=0，读写共享 128 位数据通道，上限为 16 B/周期，不能把读写相加成 32 B/周期。屋顶拐点为 32 OP/B。此处是接口合同的理论上限，尚非独立带宽基准给出的持续带宽屋顶，也不是板级 DDR 模型。

实测范围	N OP	读 B	写 B	T 周期	I OP/B	P OP/周期
K96 局部，C 初值有效	393216	30720	12288	8711	9.1429	45.1402
复用关闭，C 初值无效	393216	18432	12288	7612	12.8000	51.6574
复用开启，C 初值无效	393216	15360	12288	7236	14.2222	54.3416

三行均为 M64 N32 K96，但首行来自 V023 trace 窗口[0,8711)，后两行为 V024 独立复用候选 A/B。首行日志任务周期 8707 与 trace 全窗口 8711 不同，本图统一采用与字节记录匹配的 8711，不混用两种分母。后两行可直接比较，不能与首行合成同条件加速比。

首行理论屋顶为 146.2857 OP/周期，实测达到其 30.8575%；实测为阵列理论峰值的 8.8164%。这两个比例不是逐 PE 有效 MAC 采样利用率。点位在拐点左侧，表示理论带宽屋顶较低；实际仍远低于该屋顶，需要状态记录解释差距，不能直接认定 DDR 已满。

4.3 优化前后与资源状态

项目	关闭复用	开启复用	同条件变化
AXI 任务周期	7612	7236	−4.94%
权重读取	6144 B	3072 B	−50%
全部读取	18432 B	15360 B	−16.67%
读写合计	30720 B	27648 B	−10%
输出写回	12288 B	12288 B	不变
新增存储数组	基线	无新增数组	复用原有 A/W 缓存；控制逻辑变化
LUT FF BRAM DSP Fmax 功耗	未提交新报告	未提交新报告	不能由数组数量推导物理资源

复用优化仅为独立候选，尚未合入统一顶层。不同优化候选的收益不相乘。

下一步按双缓冲生命周期实现“预取下一块、计算当前块”，再隔离写回反压形成读算写流水；保留权重驻留，覆盖奇数尾块与跨 K 部分和。验收要求输出一致、字节对账、同域有效计算与搬运交集可测、完成周期下降。已有候选应先重现，再逐项集成，不能把概念时序作为实测效果。

4.4 整改方案与封存

当前版本执行效率偏低。源码已有双缓冲、下一 K 块预取和 II=1 结果收集，整改优先核对 COLLECT 与 packer 之间的反压，补齐逐 PE 有效事件，再隔离结果队列、优化段命令与调度。详见整改方案，包含 R0 至 R3、验收条件和停止条件。整改仍为待实施安排，不作为封存版本的已实现收益。

5 大模型协作记录

本节保留本会话可确认的协作过程。协作工具为 Codex；未记录的精确模型版本、其他历史智能体内部提示词和返回不补写。可见任务中虽有早期多智能体分工，当前 skill 与 Roofline 修复由本会话串行完成。

用户提示或反馈	模型处理	纠错与可核验证据
固定架构和量化，暂不展示不确定数据	保留 W7p8/A16/C48 主线，分离历史实验与 RTL 局部结果	data 目录保留范围与原始记录
布局、向量难懂，改图与量化四宫格	展示名改为数据重排、结果处理；独立 DMA 搬运	图片与 RTL 名称映射保留
搬运与计算为何不重叠	撤下容易误读的忙闲宣传图，核对握手交集	busy 不等于有效 MAC，不能宣称完全无重叠或充分重叠
先修复 skill，再做标准 Roofline	修复 busy 误标 compute，添加独立 Roofline 核算入口	10 项账本自测、8 项波形自测及 4 项 Roofline 测试
按竞赛要求优化目录和报告	新建英文提交副本，保留原工程	readme.md 目录映射与复现命令

关键纠错包括：依据实际编译参数确认 K96 样例 M=64 而非 32；确认共享 DUPLEX=0 带宽不能相加；同一任务的 Q/T 只是实际平均流量，不能反过来作为其 Roofline 带宽上限。源码和输入哈希见 data/sources_sha256.json。

6 技能包提炼过程

6.1 从观测问题提炼

最初观测以模块 busy 显示阶段，旧接入脚本将 busy 命名为 compute，存在把忙状态当成有效计算的风险。traffic-ledger 与 module-activity-waveform 现在依据明确 busy 证据将这类旧状态归为 busy，保留 original_state，不改原始 trace。波形以独立颜色显示忙状态，不能以其高电平推导有效 MAC 利用率。

6.2 与 Roofline 配合

搬运账本通过 R/W 握手和 WSTRB 统计 Q，按张量版本与逻辑范围识别重复候选。活动波形确认 T 对应的窗口及等待、收集和排空阶段。N 来自已核实矩阵尺寸；屋顶峰值来自阵列与共享接口合同。它们共同回答点在哪里、为何离屋顶远、下一步怎样移动。

对 K96 记录，Q=43008 B、T=8711 周期、N=393216 OP，得到图中橙点。其 FSM 统计包含 1632 周期计算阶段、5242 周期结果收集、1814 周期控制、20 周期等待输入、3 周期空闲，合计 8711。计算阶段仍不是逐 PE 有效 MAC 计数，结果收集占比约 60.18%是进一步检查的线索。

6.3 如何验证与适用边界

自测覆盖：张量版本不误合并、部分重叠、字节容量上限、未采样为 unknown、时钟不自动对齐、状态不重叠、busy 分类不变成有效计算、循环带宽来源拒绝、超过屋顶拒绝。实际记录重算还检查 busy 分类、Roofline 点位与读写总量。工具测试通过不等于 RTL 或板卡通过。

技能仅分析已记录事件；不把 Python 墙钟换成硬件周期，不在无跨域锚点时合并时钟，不把重复候选直接当可节省流量，不以图片证明硬件实现。源级量化合同、舍入和数值顺序均保持不变。

7 复现说明

完整命令与依赖见仓库 readme.md。复现分为现有测量的分析重算与统一小图 RTL 重新仿真，两者范围不同。

```
cd asr_submission
bash build/reproduce_analysis.sh
bash build/run_rtl.sh
```

分析需要 Python 3、Matplotlib 与 NumPy，账本和波形工具自身使用标准库。RTL 需要 Icarus Verilog、vvp、Python 3 及 NumPy、bash 和 timeout。脚本失败会返回非零。统一 RTL 入口重新生成确定性 fixtures 和独立 gold，检查正常完成的写响应排空，并运行错误路径；结果保存在 sim/unified_run。

分析复现重算既有 Roofline 点，并不重新执行原 V023/V024 专用性能测试。专用测试源码位置、哈希、任务尺寸与原始记录随 data 保存；其复用候选未集成到 src/unified。仓库不包含完整 591 张量 ASR 端到端输入、板卡 bitstream 或新的综合时序结果，复现承诺仅覆盖上述明确入口。

参考资料

1. Williams, Waterman, Patterson. Roofline. Berkeley technical report EECS-2008-134，https://www2.eecs.berkeley.edu/Pubs/TechRpts/2008/EECS-2008-134.html 。用于 Roofline 定义与理论形式。

2. Chen, Emer, Sze. Eyeriss. ISCA 2016，本地参考论文。

3. Genc 等. Gemmini. arXiv:1911.09925，本地参考论文。

4. 项目统一导出 ARCHITECTURE、ABI、MERGE_TABLE 与验证日志，原始位置和哈希随 data 记录。